目标检测基础学习笔记

以 ResNet FPN 和 FCOS 为主线的系统学习材料

本笔记系统梳理现代目标检测的基本流程，重点解释 Backbone、Neck、Head、标签分配、损失函数、训练、推理与评价指标之间的关系，并结合水下目标检测说明多尺度特征和小目标检测的重要性。文中以 ResNet + FPN + FCOS 为主线；其他检测器可能采用不同的检测头、匹配机制或后处理流程。

阅读目标：理解一张输入图像如何经过特征提取、特征融合和检测头预测，最终生成类别、置信度与边界框；能够区分训练阶段和推理阶段，并为后续阅读注意力机制、Transformer 与 RHCNet 做准备。

知识地图

模块	核心内容	输出或作用
Backbone	CNN、Conv、Padding、Downsampling、ResNet	提取多层级 Feature Map
Neck	FPN、Upsampling、Lateral Connection、Add	融合不同尺度特征
Head	Classification、Regression、Centerness	预测类别、LTRB 与中心度
Training	Label Assignment、Focal Loss、IoU/GIoU Loss、反向传播	更新网络参数
Inference	解码、置信度筛选、NMS	输出最终检测结果
Evaluation	Precision、Recall、AP、mAP	衡量检测效果

一 目标检测是什么

目标检测是计算机视觉中的核心任务。它不仅需要识别图像中有什么物体，还需要确定物体在图像中的具体位置。对于水下图像，模型可能需要识别鱼、海参、海胆等目标，并为每个目标预测类别和边界框。

最终输出通常包含：

$$\text{Detection} = (\text{Class}, \text{Confidence}, \text{Bounding Box})$$

- Class：目标类别。
- Confidence：模型对检测结果的置信度。
- Bounding Box：目标在图像中的位置。

二 目标检测的整体架构

现代目标检测模型通常可以拆分为三个核心部分：Backbone 主干网络负责提取特征，Neck 特征融合网络负责整合不同尺度的特征，Head 检测头负责分类和定位。

部分	主要任务	典型组件
Backbone	从输入图像提取视觉特征	ResNet、VGG、CSPDarknet、ConvNeXt、Swin Transformer
Neck	融合不同层级和尺度的特征	FPN、PAN 等
Head	输出类别与位置预测	分类、回归、中心度或其他预测分支

1 Backbone 特征提取

Backbone 的主要任务是从输入图像中提取有用的视觉特征。原始图像包含大量像素信息，直接对所有像素进行目标识别并不高效，因此需要通过 CNN 将图像转换为具有不同层次的 Feature Map。

常见 Backbone 包括 ResNet、VGG、CSPDarknet、ConvNeXt 和 Swin Transformer。以 ResNet 为例，它通过多个卷积阶段逐步提取图像特征。

卷积层 Conv

卷积核在输入图像上滑动，对局部区域进行加权计算，提取边缘、纹理和形状等特征。

```
nn.Conv2d(
    in_channels=3,
    out_channels=64,
    kernel_size=3,
    stride=1,
    padding=1
)
```

参数	含义
in_channels	输入通道数
out_channels	输出通道数
kernel_size	卷积核尺寸
stride	卷积步长
padding	填充大小

对于 RGB 图像，输入通道数为 3。一个卷积核会覆盖所有输入通道，产生一张二维特征图；多个卷积核则产生多个输出通道。

Padding 填充

Padding 是在特征图边缘补充像素，常见方式是 Zero Padding。卷积输出尺寸为：

$$H_{\text{out}} = \text{floor}\left(\frac{H + 2P - K}{S}\right) + 1$$

例如输入为 5×5，卷积核为 3×3，Stride 为 1，Padding 为 1，输出尺寸仍为 5×5。Padding 可以控制输出空间尺寸，也让边缘位置参与卷积计算；它不等于恢复丢失的信息。

下采样 Downsampling

下采样降低特征图空间分辨率，例如 640×640 → 320×320 → 160×160。常见方法包括 Stride=2 的卷积、Max Pooling 和 Average Pooling。下采样可以减少计算量、扩大深层特征的感受野并逐步整合更大范围的图像信息，但也可能损失小目标的细节，因此目标检测需要多尺度特征。

ResNet 残差网络

普通深层网络随着深度增加，可能出现优化困难和网络退化问题。ResNet 引入残差连接，核心公式为：

$$H(x) = F(x) + x$$

其中 x 是输入特征，F(x) 是残差分支学习到的变化，H(x) 是最终输出。网络不必直接学习完整映射，而是学习输入需要改变的部分。

```
输入 x
  |
Conv 3×3
  |
BN
  |
ReLU
  |
Conv 3×3
  |
BN
  |
  +  ← Shortcut（输入 x）
  |
ReLU
  |
输出
```

如果输入和输出形状不一致，可以使用 Projection Shortcut，常见做法是用 1×1 卷积调整通道数或空间尺寸。

ResNet 的多阶段输出

以 ResNet-18 为例，输入为 [1, 3, 224, 224]，典型阶段输出如下：

阶段	输出形状
Stem	[1, 64, 56, 56]
Layer1	[1, 64, 56, 56]
Layer2	[1, 128, 28, 28]
Layer3	[1, 256, 14, 14]
Layer4	[1, 512, 7, 7]

这里的 Stem 包括 7×7 卷积和 Max Pooling。随着网络加深，特征图空间尺寸逐渐减小，通道数通常逐渐增加，深层特征更适合表达高级语义，浅层特征保留更多空间细节。目标检测通常需要保留多个阶段的输出，而不是像分类任务那样只使用最后一层特征。

2 Neck 特征融合

不同层级的特征各有优势：浅层特征空间分辨率高、细节丰富，但语义较弱；深层特征语义信息丰富、感受野大，但空间分辨率低。对于水下目标检测，远处的小鱼需要高分辨率特征，而较大的海参需要更丰富的语义信息，因此需要融合不同层级的特征。

特征	优势	不足
浅层特征	空间分辨率高、细节丰富	语义信息较弱
深层特征	语义信息丰富、感受野大	空间分辨率低

FPN Feature Pyramid Network

FPN 是经典的多尺度特征融合结构，主要包含 Top-down 上采样、Lateral Connection 横向连接和逐元素相加三个操作。

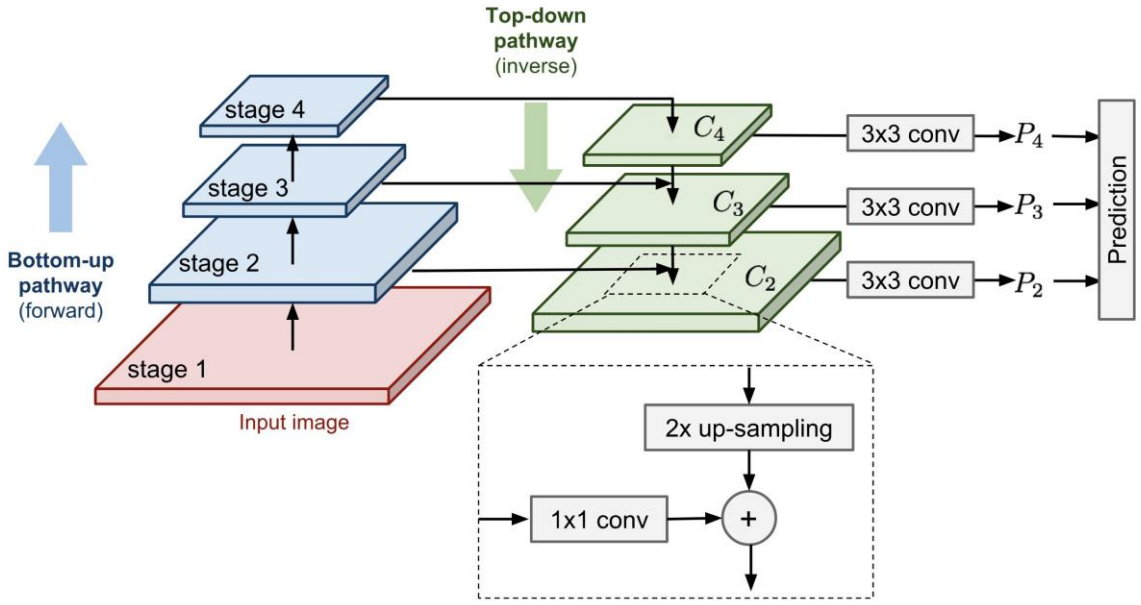


图 1 FPN 的自底向上路径、自顶向下路径与横向连接

第一步是 Top-down 上采样，将高层特征图放大，使空间尺寸与低层特征图一致，例如 7×7 → 14×14。这是 Upsampling，不是 Padding。第二步是使用 1×1 卷积调整低层特征的通道数，使其能与上采样后的高层特征相加。第三步是逐元素相加，要求两个张量形状一致。之后通常使用 3×3 卷积进一步处理融合后的特征。

$$M_4 = \mathrm{Conv}_{1x1}(C_4) + \mathrm{Up}(M_5)$$

$$M_5 = \mathrm{Conv}_{1x1}(C_5)$$

$$M_l = \mathrm{Conv}_{1x1}(C_l) + \mathrm{Up}(M_{l+1})$$

$$P_l = \mathrm{Conv}_{3x3}(M_l)$$

例如 C_4 为 [1, 1024, 14, 14]，经过 1×1 卷积后变为 [1, 256, 14, 14]。最终得到多个尺度的特征图 P_2、P_3、P_4、P_5。输入图像为 640×640 时，常见输出尺寸如下：

特征层	空间尺寸	Stride
P2	160×160	4
P3	80×80	8
P4	40×40	16
P5	20×20	32

上采样不会凭空恢复已经丢失的细节。FPN 通过横向连接引入浅层特征，弥补高层特征空间细节不足。

Add 和 Concat 的区别

操作	Add	Concat
操作方式	逐元素相加	沿指定维度拼接
形状要求	所有维度一致	除拼接维度外一致
输出通道	不变	通常增加
常见用途	FPN、残差连接	特征拼接、特征融合

3 Head 检测头

Head 根据融合后的特征预测目标类别和位置。以 FCOS 为例，检测头主要包含 Classification Branch、Regression Branch 和 Centerness Branch 三个分支。

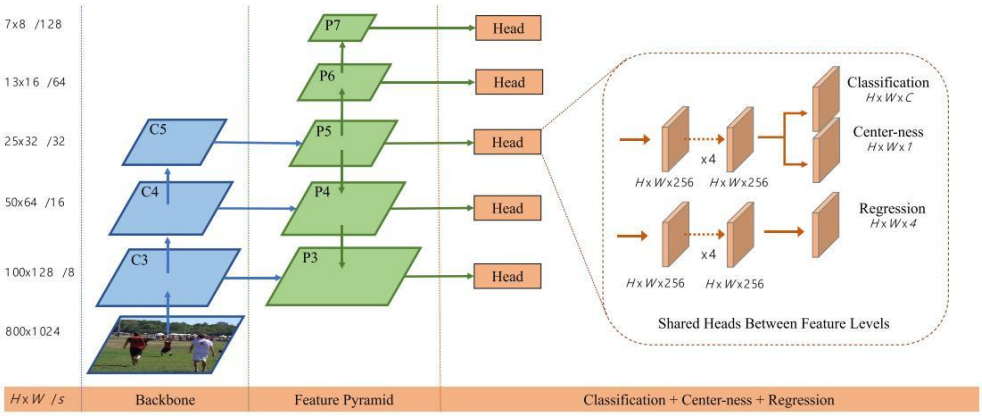


Figure 2 – The network architecture of FCOS, where C3, C4, and C5 denote the feature maps of the backbone network and P3 to P7 are the feature levels used for the final prediction. $H \times W$ is the height and width of feature maps. '/s' ($s = 8, 16, ..., 128$) is the down-sampling ratio of the feature maps at the level to the input image. As an example, all the numbers are computed with an 800×1024 input.

图 2 FCOS 的 Backbone、特征金字塔与分类、中心度、回归分支

分类分支

分类分支判断每个位置是否存在目标，以及目标属于哪个类别。

```
cls_conv = nn.Conv2d(256, num_classes, 1)
```

如果只有一个类别，[1, 256, 80, 80] → [1, 1, 80, 80]。输出是 Logits，经过 Sigmoid 转换为概率：

$$P = \frac{1}{1 + e^{-x}}$$

当 x = 2.5 时，P ≈ 0.924，表示该位置属于目标类别的预测概率约为 0.924。

边界框回归分支

FCOS 属于 Anchor-Free 检测器，不依赖预先设置的 Anchor Box，而是以特征图上的位置作为参考点，预测到目标边界的距离。四个预测值为 (l, t, r, b)，分别表示到左、上、右、下边界的距离。

例如真实框为 GT=(204, 134, 304, 214)，参考点为 (x, y)=(244, 164)，回归标签为：

$$(l, t, r, b) = (40, 30, 60, 50)$$

预测框解码公式为：

$$x_1 = x - l \quad y_1 = y - t \quad x_2 = x + r \quad y_2 = y + b$$

最终得到 BBox=(204, 134, 304, 214)。

Stride 与坐标映射

假设输入图像为 640×640，P3 特征图为 80×80，Stride 为 8。对于特征图位置 (i, j)=(20, 30)，采用网格中心坐标约定：

$$x = (j + 0.5)\,x\,8 = 244 \quad y = (i + 0.5)\,x\,8 = 164$$

因此对应原图参考点为 (244, 164)。这是本笔记使用的网格中心约定，具体检测器实现可能采用不同的坐标约定。

Centerness 中心度

即使一个点在真实目标框内部，也不一定适合用来预测整个目标框。越靠近目标边缘的位置，预测框的定位质量往往越不稳定。FCOS 引入中心度分支，衡量参考点相对于目标中心的位置是否均衡。

$$C* = \sqrt{\left(\frac{\min(l, r)}{\max(l, r)}\right) x \left(\frac{\min(t, b)}{\max(t, b)}\right)}$$

点 A 位于目标中心，LTRB=(100,100,100,100)，中心度为 1；点 B 靠近边缘，LTRB=(10,10,190,190)，中心度约为 0.0526。中心度越接近 1，说明参考点越靠近目标中心。推理时常将分类分数与中心度分数结合：

$$\text{Score} = \sqrt{(P_{\text{cls}}\,x\,P_{\text{center}})}$$

三 目标分配 Label Assignment

模型训练时，需要确定特征图上的哪些位置负责预测哪个目标，这个过程叫 Label Assignment。以 FCOS 为例，一个位置通常需要满足以下条件才能成为某个 GT 的正样本。

1 必须位于真实目标框内部。参考点在目标框外，通常不能负责预测这个目标。

2 Center Sampling。如果启用中心采样，正样本必须进一步靠近目标中心。例如目标框为 (100,100,300,300)，中心点为 (200,200)，Stride=8，采样半径系数 r=1.5，则 R=1.5×8=12，中心采样区域为 (188,188,212,212)，位于该区域内的点才满足中心采样条件。

3 Regression Range。不同 FPN 层负责不同尺寸范围的目标。根据该位置的最大回归距离 m=max(l,t,r,b)，判断应该由哪个尺度的特征层负责预测。

特征层	回归范围
P3	0–64
P4	64–128
P5	128–256
P6	256–512

真实 FCOS 实现的范围边界和分配细节可能有所不同。

四 Loss 损失函数

模型训练时需要将预测结果与真实标签进行比较。预测越接近真实标签，损失通常越小。

Classification Loss

分类损失用于衡量类别预测是否正确，常见损失包括 BCE Loss 和 Focal Loss。目标检测中负样本通常远多于正样本，例如正样本 50 个、负样本 6350 个，负样本占比约 99.22%。大量简单负样本会影响训练，因此 Focal Loss 降低容易分类样本的损失权重。

$$\mathrm{FL}(p_\mathrm{t}) = -\alpha_\mathrm{t}\,(1 - p_\mathrm{t})^{gamma}\log(p_\mathrm{t})$$

- p_t：模型对真实类别的预测概率。
- α_t：类别平衡系数。
- γ：调节简单样本权重的参数。

当样本容易分类时，p_t 接近 1，损失权重会明显降低。Focal Loss 不只是降低负样本权重，容易分类的正样本也会被降低权重。

Bounding Box Regression Loss

回归损失衡量预测框与真实框之间的差异，常见方法包括 L1 Loss、Smooth L1 Loss、IoU Loss、GIoU Loss、DIoU Loss 和 CIoU Loss。

IoU 衡量预测框和真实框的重叠程度：

$$\mathrm{IoU} = \frac{\mathrm{A_{intersection}}}{\mathrm{A_{union}}}$$

Intersection 是交集面积，Union 是并集面积。IoU 越接近 1，说明两个框重叠程度越高。

$$L_{\mathrm{IoU}} = 1 - \mathrm{IoU}$$

IoU 的局限是：当两个框完全不重叠时，IoU 都为 0，无法体现几何距离。GIoU 引入同时包围两个框的最小外接矩形：

$$\mathrm{GIoU} = IoU - \frac{(C - \mathrm{A_{union}})}{C}$$

- C：最小外接矩形面积。
- A_union：两个框的并集面积。

$$L_{\mathrm{GIoU}} = 1 - \mathrm{GIoU}$$

总损失

训练时通常将分类损失和回归损失组合，FCOS 还会有中心度损失。一个简化表达为：

$$L = L_{\mathrm{cls}} + \lambda_1 L_{\mathrm{reg}} + \lambda_2 L_{\mathrm{center}}$$

不同模型的损失构成、权重和计算方式可能不同。

五 模型训练过程

训练的核心是：模型先进行预测，再计算损失，最后根据梯度更新参数。完整过程为：

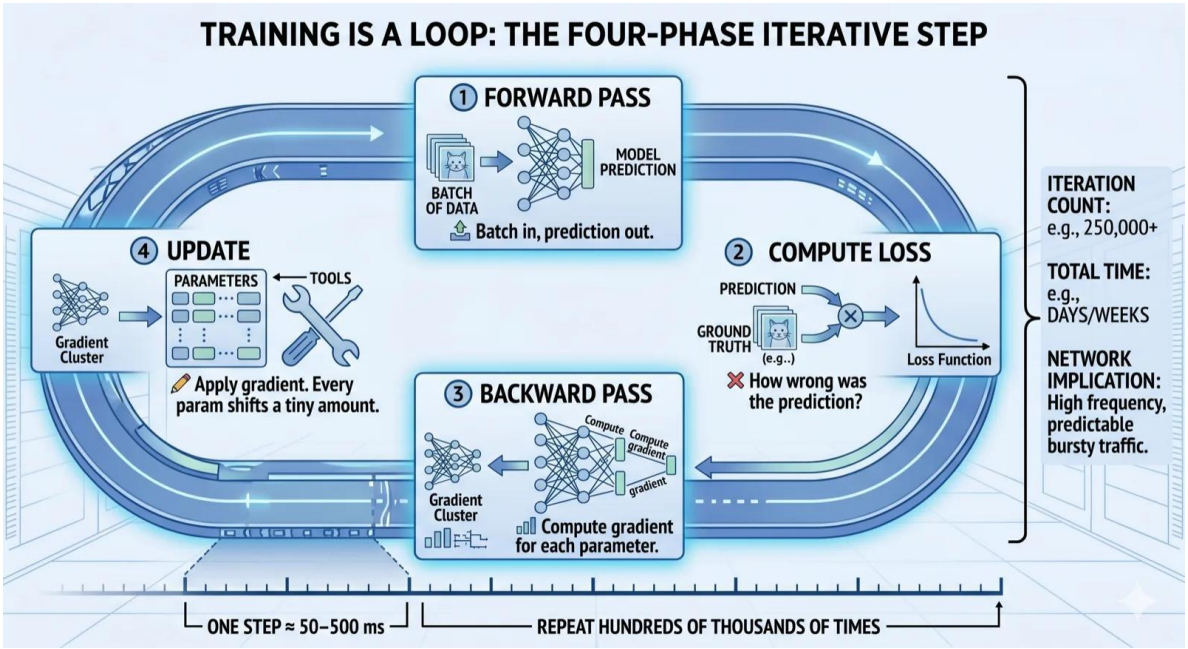


图 3 训练循环：前向传播、损失计算、反向传播与参数更新

- 输入图像和 Ground Truth。
- Backbone 提取特征。

- Neck 融合多尺度特征。
- Head 输出分类、回归和中心度预测。
- 根据 Ground Truth 进行标签分配。
- 计算各分支 Loss。
- 反向传播，计算参数梯度。
- 优化器更新模型参数。

```
optimizer.zero_grad()

outputs = model(images)

loss = compute_loss(outputs, targets)

loss.backward()

optimizer.step()
```

- zero_grad()：清空上一次累积的梯度。
- backward()：计算梯度。
- step()：根据梯度更新模型参数。

训练的目的就是不断调整网络参数，让预测结果逐渐接近真实标签。

六 模型推理过程

训练和推理是两个不同阶段。训练阶段需要计算 Loss、反向传播和更新参数；推理阶段不需要更新参数，而是根据训练好的模型直接进行预测。

- 输入图像。
- Backbone 提取特征。
- Neck 融合多尺度特征。
- Head 预测类别、LTRB 和中心度。
- 将 LTRB 解码成原图 Bounding Box。
- 根据置信度筛选候选框。
- 使用 NMS 去除重复框。
- 输出最终检测结果。

NMS 非极大值抑制

NMS 的作用是去除同一个目标周围重复的预测框。基本步骤是：

- 按照置信度从高到低排序。
- 选择最高分的框。
- 计算它与其他框的 IoU。

- 如果 IoU 超过设定阈值，则抑制重叠框。
- 重复执行，直到处理完候选框。

NMS 是 FCOS、YOLO 等许多检测器常见的后处理方式，但并非所有检测器都需要它。例如原始 DETR 使用集合预测和匹配机制，通常不依赖传统 NMS。

七 目标检测评价指标

TP FP FN

- TP：正确检测到的目标。
- FP：错误检测出来的目标。
- FN：没有检测到的真实目标。

Precision 精确率

$$\text{Precision} = \frac{TP}{(TP + FP)}$$

表示模型预测出来的目标中，有多少是真的。

Recall 召回率

$$\text{Recall} = \frac{TP}{(TP + FN)}$$

表示真实存在的目标中，有多少被模型检测出来。

AP 和 mAP

AP 是某一类别的检测评价指标，通常可以理解为 Precision-Recall 曲线下的面积。mAP 是多个类别 AP 的平均值。

指标	含义
AP50	IoU 阈值为 0.5 时的 AP
AP75	IoU 阈值为 0.75 时的 AP
AP50:95	在 IoU 0.50 至 0.95、步长 0.05 的多个阈值下求平均
mAP	多个类别 AP 的平均值

阅读论文时，不能只看 mAP 数字，还需要确认使用的数据集、评价协议、IoU 阈值、输入分辨率，以及参数量和计算量是否相近。

八 不同目标检测架构的区别

前面学习的是 FCOS，并不是所有目标检测器都采用 FCOS 的结构。不同架构在候选框生成、目标匹配、损失函数和后处理等方面可能不同。

类型	代表模型	核心特点
两阶段检测器	Faster R-CNN	先生成候选区域，再分类和定位
单阶段检测器	YOLO	直接预测类别和边界框
Anchor-Free	FCOS	以特征图位置为参考点预测边界距离
Transformer 检测器	DETR	使用 Object Queries 进行集合预测

九 结合水下目标检测研究

水下图像存在颜色失真、对比度低、水体散射造成模糊、前景与背景难以区分、目标细节丢失和小目标检测困难等典型问题。这些问题会影响目标检测模型的特征提取、特征融合和边界框定位。

研究方向	主要目的
图像增强	改善图像颜色、对比度和清晰度
特征增强	提升模型对有效目标特征的表达能力
注意力机制	强调重要特征，抑制无关信息
多尺度融合	改善不同尺寸目标的检测效果
特征校准	减少不同层级特征之间的偏差
小目标检测	提升远距离、小尺寸目标的识别能力

这些方向也是后续精读 RHCNet 时需要重点关注的内容。

十 这一阶段的知识结构

目标检测知识地图可以概括为以下主线：

- Backbone：CNN → Conv → Padding → Downsampling → ResNet → Feature Map。
- Neck：多尺度特征 → FPN → Upsampling → Lateral Connection → Add。
- Head：Classification → Regression → Centerness → Bounding Box。

- Training：Label Assignment → Focal Loss → IoU/GIoU Loss → Backpropagation。
- Inference：Decoding → Confidence Filtering → NMS → Detection Results。
- Evaluation：Precision → Recall → PR Curve → AP → mAP。

接下来的学习路线：

- Attention 机制：从 Q、K、V 开始，理解注意力如何计算。
- Transformer：理解 Self-Attention、Multi-Head Attention、Encoder。
- 特征增强模块：理解通道注意力、空间注意力、跨尺度融合。
- 回到 RHCNet：结合原文和代码，逐模块理解作者的设计动机、公式和实验。

这份笔记可以作为目标检测基础阶段的总复习材料。后续阅读论文时，可在遇到具体问题时回到对应章节补充 CNN、FPN、FCOS、损失函数或评价指标。

复习自测

建议先遮住检查要点，用自己的话回答，再回看前文核对。

自测问题

1. Backbone、Neck 和 Head 分别负责什么？一张图像经过它们时，特征如何流动？
2. 浅层和深层特征各有什么优缺点？FPN 如何结合它们？上采样为什么不能恢复已丢失的细节？
3. FCOS 的参考点如何用 (l, t, r, b) 解码边界框？中心度分支解决什么问题？
4. 训练时哪些位置会成为正样本？Center Sampling 和 Regression Range 分别起什么作用？
5. 训练和推理的步骤有什么不同？NMS 用什么依据抑制重复框？
6. Precision、Recall、AP 和 mAP 分别衡量什么？AP50 与 AP50:95 有什么差别？

检查要点

- Backbone 提取特征，Neck 融合多尺度特征，Head 预测类别与位置。
- 浅层分辨率高、细节多但语义弱；深层语义强但分辨率低。FPN 自顶向下上采样，并通过横向连接融合浅层信息。
- 边界坐标为 (x-l, y-t, x+r, y+b)。中心度衡量参考点是否靠近目标中心，帮助降低定位质量较差的预测分数。
- 正样本一般需位于 GT 内部，并可受中心采样约束；回归范围将不同尺寸目标分配给不同 FPN 层。
- 训练包含损失计算、反向传播和参数更新；推理只前向预测并做筛选和后处理。NMS 按分数排序，再按 IoU 阈值抑制重叠框。
- Precision 关注预测为正的结果有多准，Recall 关注真实目标找回多少；AP 概括单类 PR 表现，mAP 是类别 AP 的均值。AP50:95 在多个 IoU 阈值上平均。